



农业图书情报学报

Journal of Library and Information Science in Agriculture

ISSN 1002-1248, CN 10-1680/G2

《农业图书情报学报》网络首发论文

题目：生成式人工智能迭代中的个人信息安全治理：基于大模型技术演进视角
作者：安琳
DOI：10.13998/j.cnki.issn1002-1248.25-0750
收稿日期：2025-12-25
网络首发日期：2026-03-05
引用格式：安琳. 生成式人工智能迭代中的个人信息安全治理：基于大模型技术演进视角[J/OL]. 农业图书情报学报.
<https://doi.org/10.13998/j.cnki.issn1002-1248.25-0750>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

生成式人工智能迭代中的个人信息安全治理： 基于大模型技术演进视角

安琳

(陕西省图书馆, 西安 710061)

摘要：[目的/意义]旨在从生成式人工智能模型的技术迭代视角出发，构建以风险分级为核心的个人信息安全治理框架，探索生成式人工智能技术革新过程中兼顾创新发展与个人信息安全保护的可行路径，弥补现有研究缺乏技术演进视角的不足。[方法/过程]比较国内外主流大模型技术差异，剖析生成式人工智能在各环节面临的个人信息安全风险。基于DeepSeek技术创新要点，结合中国现行治理政策，提出一个以包容审慎为核心、风险分级为导向、覆盖各运行阶段的综合治理框架。[结果/结论]基于个人信息敏感程度构建覆盖数据采集、模型运行与内容生成的全流程风险分级治理体系。DeepSeek的开源可溯、决策透明和灵活部署等技术特性，为实施分级治理提供了关键支撑，有助于实现安全管控与技术创新的动态平衡，为中国构建适应技术发展的个人信息安全治理模式提供了实践参考。

关键词：生成式人工智能；个人信息安全；DeepSeek；风险分级

中图分类号：G203；D923.7

文献标识码：A

文章编号：1002-1248 (XXXX) XX-0001-10

引用本文：安琳. 生成式人工智能迭代中的个人信息安全治理: 基于大模型技术演进视角[J]. 农业图书情报学报, XXXX, XX (XX): 1-10.

0 引言

在生成式人工智能迅猛发展的浪潮中，2022年11月美国OpenAI公司发布的ChatGPT无疑具有里程碑意义。它不仅推动了自然语言处理技术的普及应用，更以强大的内容生成与交互能力，拉开了人工智能通用大模型时代的序幕。2023年12月，美国谷歌公司发布首个多模态大模型Gemini，凭借在多模态理解和推理能力上的突破，Gemini已在多项基准测试中超越ChatGPT，引领生成式人工智能进入感知与认知深度融合的新阶段。然而，生成式人工智能在推动人机交互

互范式革新与应用拓展的同时，也暴露出个人信息安全方面的多重隐忧，一旦处理不当极易侵犯个人隐私，甚至引发规模性风险^[1]。例如，2023年6月，美国加州一律师事务所指控OpenAI非法收集数亿用户的私人对话和医疗数据用于模型训练^[2]。2026年1月，谷歌Gemini爆出“日历间谍”漏洞，将深度集成办公生态的Gemini从办公助手变为窃取私人数据的监控工具^[3]。事实上，以ChatGPT、Gemini为代表的国外主流模型在数据收集、模型运行、算法迭代及内容生成等环节均存在个人信息安全风险，且随着模型从单模态扩展到多模态，个人信息安全的范畴与风险复杂

收稿日期：2025-12-25

基金项目：陕西省文化和旅游厅2025年度文化和旅游课题“陕西城乡新型公共文化空间建设研究”（2025WL37）

作者简介：安琳（1987-），女，硕士，副研究馆员，研究方向为信息权利和知识管理

度也急剧增加。

2025年1月,中国深度求索公司推出DeepSeek R1模型,该模型以开源开放、决策透明、部署灵活为核心特征,不仅在架构效率与推理能力上实现跃升,更推动了生成式人工智能从封闭黑箱走向透明可信、从集中式服务走向分布式赋能的生态转型。同年10月DeepSeek OCR模型发布,2026年2月升级为OCR2版本。在延续R1模型开源、高性能、灵活部署的基础上,实现了对图像文本信息的精准理解与生成,展现了本土大模型向多模态领域进军的强大潜力^[4]。从国外ChatGPT、Gemini到国内DeepSeek的技术迭代,不仅是模型能力的提升,更是为构建兼顾创新发展与安全保障的个人信息安全治理体系提供了可行的技术内生性策略。在此背景下,本研究立足国内外主流大模型的技术演进视角,系统分析了生成式人工智能迭代过程中的个人信息安全挑战与DeepSeek技术创新导向下的个人信息安全治理策略,旨在为中国在新技术环境下构建可持续的生成式人工智能个人信息安全治理框架提供理论参考与实践路径。

1 生成式人工智能视域下个人信息安全治理研究现状

当前学界围绕生成式人工智能应用所引发的个人信息保护问题已展开多维度探讨。现有研究普遍指出以ChatGPT为代表的生成式人工智能技术在数据处理层面存在告知同意规则虚化、最小必要原则难以落实、虚假信息生成与个人信息泄露风险加剧等问题,并提出了相应的治理路径^[5]。已有研究主要从法律规制、风险防控等角度出发,强调应构建以风险控制为导向的保护机制^[6],推动个人信息保护从权利保护向风险控制范式转型^[7],并倡导依据生成式人工智能的不同应用阶段采取分阶治理策略^[8]。此外,部分研究关注敏捷治理与信义保护等新兴路径,进一步拓展了治理视角。前者强调通过快速响应、动态调整与多元协同,以灵活适应生成式人工智能的快速迭代与风险不确定性^[9]。后者则主张构建用户与服务提供者间的信义关系,通过强化服务提供者的忠实与勤勉义务,推动保护模式从“静态赋权”转向“责任约束”^[10]。

综上研究为构建生成式人工智能视域下的个人信息安全治理研究框架提供了重要思路。

随着DeepSeek系列模型的问世与快速崛起,学界开始关注其带来的技术突破及相应的治理新议题。现有文献指出,DeepSeek通过开源生态、思维链技术、知识蒸馏与灵活部署等创新,实现了低成本、高性能与高透明度的跃升^[11,12],部分研究提出,作为本土应用,DeepSeek以《网络安全法》《数据安全法》《个人信息保护法》《生成式人工智能服务管理暂行办法》等法律法规为遵循,通过采取制定一系列隐私政策等个人信息保护合规举措,消减了部分安全风险^[13]。也有研究提出DeepSeek技术创新能够提供应对风险的手段,初步探讨了DeepSeek思维链模式、主动开源等技术特性对缓解“算法黑箱”、增强监管审查便利性等方面的积极影响^[14]。

然而,目前大多数生成式人工智能视域下的个人信息保护研究多以ChatGPT等国外主流模型为分析对象,未能充分关注DeepSeek等新一代模型的技术跃迁对个人信息保护的差异化影响,以及此种技术革新如何重塑全流程个人信息安全治理策略。为弥补上述研究空白,本研究重点剖析生成式人工智能技术迭代对个人信息保护的积极影响,并结合中国现行治理政策,探讨DeepSeek技术创新为构建以包容审慎为核心、风险分级为导向、覆盖生成式人工智能各运行阶段的个人信息安全治理体系所提供的全新可能性与实施路径。

2 生成式人工智能模型技术迭代概述

2.1 模型生态:从闭源到开源

一是从架构透明性角度,DeepSeek系列模型(包括R1与最新的OCR2)架构对公众开放,用户可查看了解模型的构建细节,从而为模型优化提供了基础。而ChatGPT和Gemini系列作为闭源模型,其内部架构和参数设置对用户不可见;二是从模型扩展性角度,DeepSeek具有高度模块化的特点,支持用户按需进行灵活扩展定制。ChatGPT和Gemini系列受限于闭源性质,用户只能通过API进行有限定制,无法直接对模型进行深度优化;三是从社区创新性角度,DeepSeek

通过 GitHub 等平台开放模型下载，以广泛的社区参与快速推动技术的迭代创新与行业适用性。相比之下，国外闭源模型优化主要依赖于开发团队内部的力量，难以形成社区层面的技术创新与积累^[15]。

2.2 模型能力：从泛化到强化

一是从架构类型角度，DeepSeek在传统Transformer架构基础上创新性融入混合专家架构，有效实现计算成本和性能的平衡^[16]。国外以ChatGPT为代表的稠密架构虽赋予模型较强的泛化能力，但计算成本消耗较大。以GPT-4为例，其参数规模达1.8万亿，单次训练成本超千万美元；而DeepSeek R1约6 710亿参数，但在处理每个具体请求时，仅动态激活约370亿参数，在获得强大性能的同时，有效平衡了计算成本与吞吐效率^[17]。二是从训练策略角度，DeepSeek创新性采用冷启动微调和基于群体相对策略优化的强化学习训练策略，大幅降低对人工标注数据的依赖，同时有效提升模型的自主推理能力^[18]。三是从结果输出角度，

DeepSeek具有原生思维链机制，能够提供决策透明的结果输出，有助于用户理解和优化模型推理过程。而ChatGPT、Gemini等内部决策逻辑不可见，在一定程度上削弱了用户对人工智能服务的可信度^[19]。

2.3 模型部署：从单一到灵活

DeepSeek支持从云端到本地多种部署方式。用户可选择在主流云平台上完成部署以降低成本并实现弹性扩展，也可以在内部服务器进行部署以避免数据泄露并便于系统集成，亦可结合两者优势，满足数据安全和系统扩展的多重需求。此外，DeepSeek还推出参数规模从1.5B到70B不等的蒸馏版模型，这些蒸馏模型在保持较高性能的同时，显著降低了算力需求。这意味着用户可按需选择适当规模的模型进行轻量化部署，从而实现性能和成本之间的平衡。而ChatGPT和Gemini仅支持参数规模固定的全云端部署，用户难以灵活调整部署架构^[20]。ChatGPT、Gemini、DeepSeek三大主流模型技术特点对比详见表1。

表1 国内外生成式人工智能主流模型技术特点对比

Table 1 A cross-border comparison of mainstream generative AI model technologies

对比维度	OpenAI (ChatGPT 系列)	Google (Gemini 系列)	DeepSeek (DeepSeek R1)
模型特点	泛化：以通用对话与强泛化能力为核心，在广泛任务中表现均衡	多模态：采用原生多模态架构，在视频理解、跨模态检索等领域较为突出	推理：采用混合专家架构与强化学习策略，专精于复杂逻辑推理
模型生态	闭源：模型架构与参数不公开，仅能通过API进行有限定制	闭源：模型核心闭源，通过API广泛开放，与Android等谷歌生态深度绑定	开源：模型架构对公众透明，支持社区协同创新与自由定制
模型能力	算力成本：基于稠密架构，具备强大的通用能力，但计算成本消耗大 训练数据依赖：依赖大规模、高质量的人工标注数据进行监督微调 决策过程：默认直接输出结果，不主动展示思维过程，可解释性较差	算力成本：其原生多模态和超长上下文能力依赖谷歌庞大算力资源支撑 训练数据依赖：依赖海量高质量的标注图像、视频数据，数据需求的规模和复杂性高 决策过程：提供“推理提示”等可解释性功能，但模型核心代码和完整数据不公开	算力成本：创新采用混合专家架构，有效平衡计算成本与性能 训练数据依赖：创新应用冷启动微调等强化学习策略，降低标注数据依赖 决策过程：具备原生思维链机制，推理路径可视化，代码和技术细节完全公开
模型部署	单一：仅支持参数规模固定的全云端API服务，数据需上传至服务商，用户难以灵活调整	单一：主要提供云端API服务，深度集成于谷歌云生态，用户部署选择单一，数据自主权弱	灵活：支持云端、本地及混合部署。提供不同规模的蒸馏模型，用户可按需求自主选择

3 生成式人工智能背景下的个人信息安全治理挑战

生成式人工智能本质上是大数据和算法相结合的

产物，相较于传统互联网服务，生成式人工智能在数据处理上规模化、自动化和复杂化程度显著提升。伴随着数据处理模式的改变，现有个人信息保护基础理论和相关规则在生成式人工智能广泛应用背景下面临

着严峻的适用性挑战。

3.1 数据采集环节：知情同意和最小必要原则的挑战

知情同意原则和最小必要原则是个人信息收集所应遵循的基本原则。前者规定信息处理者在收集处理个人信息时应当对信息主体进行告知，并在取得同意后方可从事相应的个人信息处理活动；后者要求个人信息收集应当限制在实现处理目的所需要的最小范围，不得过度收集^[21]。然而，生成式人工智能的技术特性对个人信息保护中的这两个基本原则提出了挑战。

从生成式人工智能的初始预训练阶段开始，其大语言模型参数的形成就依赖对海量通用数据的主动训练学习。如 OpenAI 在预训练阶段使用维基百科、搜索引擎、社交媒体等公共网站以及 Common Crawl、WebText 等大型数据集作为其训练数据来源^[22]。这些随机泛在抓取的海量数据往往未经严格筛选和过滤，其中可能混杂未经信息主体授权的个人信息。《个人信息保护法》第 13 条与第 27 条虽规定在合理范围内对已公开个人信息的处理可豁免同意，但相关法条对“合理范围”界定较为模糊，导致此类数据采集的合法性判断存在较大不确定性。此外，为提升模型泛化能力与生成质量，系统倾向于广泛、深入地收集数据，甚至无差别涵盖与生成目标无直接关联的个人信息，明显违背最小必要原则。

3.2 模型运行环节：目的限制和公开透明原则的挑战

目的限制原则要求个人信息处理应符合明确化、相关化、最小化要求。然而，生成式人工智能的运行特点使其难以满足该原则。首先，“明确化”要求在运行之初应设定具体目的，但生成式人工智能的数据处理方式存在动态、复杂和不确定的特性，导致开发者难以事先准确界定处理目的。其次，“相关性”要求处理行为应与目的紧密相关，但生成式人工智能对数据的持续学习极易导致数据使用脱离初始目的，特别是在深度学习场景中，用户交互数据可能被无限期用于模型迭代，超出服务必需范围^[23]。再者，“最小化”要求处理活动对个人权益的影响最小，然而生成

式人工智能具备强大的数据挖掘分析能力，可能在数据处理过程中对正常公开的个人信息进行聚合分析，并基于此进行过度挖掘甚至推断敏感个人信息^[24]，带来显著侵权风险。

公开透明原则要求个人信息处理应公开透明，并向个人明示处理相关事项。尽管服务提供者通过用户协议等形式力图清晰勾勒出个人信息收集与处理的轮廓，但生成式人工智能依赖的深度学习算法具有“黑箱”特性，其输入至输出的决策过程缺乏透明度和可理解性。算法黑箱的存在使用户的知情权难以得到有效保障，用户个人信息在处理过程中出现错误或偏见时亦难以调试改进，从而加剧个人信息权益被侵害的风险^[25]。

3.3 内容生成环节：质量和安全原则的挑战

质量原则要求确保个人信息准确、完整，避免因质量问题对个人权益造成不利影响。然而，生成式人工智能不具备对语义真实性的判断能力，若训练语料本身存在错误、偏见或歧视等有害信息，则可能导致虚假内容的输出，并在模型迭代过程中被持续放大传播^[26]；另外，生成式人工智能自身的复杂性和训练过程中的随机性可能导致系统不稳定而输出不准确结果^[27]，从而对质量原则构成挑战，并可能损害自然人的格、人身与财产权益。

安全原则要求采取必要措施保障个人信息安全，防止信息泄露、篡改或丢失。生成式人工智能系统因其复杂性很难避免因模型设计不当、算法代码漏洞等自身因素带来的风险隐患，为恶意攻击者非法获取并泄露个人信息提供了可乘之机。例如，2023 年 3 月，OpenAI 因代码漏洞导致部分用户可查看他人聊天与支付信息^[28]。

4 DeepSeek 赋能的个人信息安全治理技术创新

4.1 开源生态：数据来源可溯化

DeepSeek 通过创新性开源共享机制打破了此前闭源大模型的垄断格局，构建了去中心化的创新生态和技术扩散范式。开源生态的透明性、协作性与灵活性

为生成式人工智能数据采集合规提供了重要支持。

开源生态的透明性使用户能够查验数据来源与方法，监督采集范围与深度，从而增强数据处理的合法性与可信度。生成式人工智能平台可依据国家标准《网络安全技术 生成式人工智能服务安全基本要求》中关于训练数据来源安全的要求，通过开源社区向用户分类展示数据来源，确保源头可追溯。如对于自采数据，应提供采集记录并明确禁止采集内容；对于开源或商用数据，则应公开授权协议或交易合同等^[29]，以证明其合法性与质量保障。目前，国际上已有“数据溯源计划”（Data Provenance Initiative）等志愿者项目，通过对训练数据集进行审计并开源相关工具，推动数据透明度提升^[30]。中国应以 DeepSeek 为引领，积极参与数据溯源实践，推动制定行业标准。

开源生态的协作性与灵活性则有助于吸引开发者、法律专家与用户共同参与数据采集的优化与监督，通过跨领域社区协作及时识别技术和法律环境变化对数据采集的影响，并基于此推动新的技术方案与合规实践指南的落地，为整个行业提供合规参考。

4.2 决策透明：模型运行可视化

DeepSeek 的透明化技术使用户能够清晰了解模型的推理过程与思考路径，革命性地突破了国外主流模型的“黑箱”逻辑^[31]。该技术通过可视化模型的决策依据，显著提升了模型的可解释性与可信度，并为个人信息保护的合规治理提供了创新技术支持。

在目的限制原则层面，DeepSeek 的可解释技术有助于建立基于数据分类的数据用途限制机制。平台可设定数据用途标签，明确不同类别信息的处理目的与范围。对于低风险的一般个人信息，可基于准确性需求允许深度加工；而对于敏感信息，原则上禁止深度处理，仅在用户为提升结论准确性而明确放弃保护时方可例外使用^[32]。该机制使用户能实时监控数据处理目的与深度的变化，防止数据被无限期用于算法迭代或违规聚合分析。

在公开透明原则层面，DeepSeek 可凭借决策透明性展示模型输入解析、参数交互至输出生成的全过程^[33]，实现数据处理各环节可追溯；同时，DeepSeek 的模型解释工具有望提供实时数据处理报告，便于用

户查询个人信息的使用频率、目的及关联情况；此外，可设置便捷反馈入口，使用户能够及时举报隐私泄露等模型不当行为，推动服务提供者及时优化算法，确保其公正合规。

4.3 灵活部署：生成端内容可控化

在生成式人工智能技术快速演进的过程中，其内容生成端面临个人信息质量与安全原则的双重挑战。DeepSeek 凭借其灵活部署特性，为应对这些挑战提供了可行的技术路径。

首先，通过在私有环境或本地服务器部署模型，DeepSeek 支持对包含个人信息的训练数据进行更严格的清洗与预处理^[34]。通过分析数据准确性与完整性，剔除存在瑕疵或偏见的数据，可从源头降低“幻觉”风险。例如，在金融领域对信用记录等敏感信息进行本地化处理，可避免生成错误的信用评估报告^[35]。同时，本地部署能确保用户交互数据物理隔离于内部服务器，并通过身份认证、权限管理等手段限制数据访问，有效防止敏感信息在训练与输出过程中被无意泄露。

其次，DeepSeek 灵活的模型架构支持基于不同场景的深度定制化训练。这种定制化能力既增强了模型对特定领域知识与逻辑规则的理解，提升输出准确性与合理性，又减少算法偏差导致的虚假内容；也便于集成加密算法、入侵检测等安全技术，实现对个人信息的全方位保护。如 2025 年初，北京、上海、深圳等地多家医院完成 DeepSeek R1 大模型的本地化部署，既实现了医疗场景的精准适配，亦保障了患者医疗数据的安全^[36]。

5 新技术环境下中国生成式人工智能个人信息安全治理策略

在生成式人工智能兴起前，中国已通过《网络安全法》《数据安全法》《个人信息保护法》等为个人信息安全治理确立了基础制度框架。自 2022 年底 ChatGPT 发布以来，国内外生成式人工智能模型呈现爆发式涌现和大规模应用的特点，上述法律难以覆盖这一技术变革给个人信息安全带来的新挑战。为促进

生成式人工智能健康发展和规范应用，中国于2023年7月颁布了《生成式人工智能服务管理暂行办法》（以下简称《办法》），对生成式人工智能开展针对性、试验性监管。《办法》对生成式人工智能服务确立包容审慎和分类分级监管原则，坚持发展和安全并重、促进创新和依法治理相结合。在个人信息安全方面，具体体现为既沿用传统立法精神明确知情同意、最小必要等个人信息保护基本原则及相关权利义务，也通过鼓励性条款支持技术赋能百业，力求在技术创新与个人权益保护间取得平衡^[37]。2025年9月，全国网络安全标准化技术委员会牵头发布《人工智能安全治理框架2.0》（以下简称《框架2.0》），进一步将“包容审慎、确保安全”作为人工智能安全治理的首要原则，全面分析包括违规收集、数据泄露等在内的个人信息安全风险，并提出针对性治理措施^[38]。《框架2.0》借鉴欧盟经验，构建了颗粒度更细的人工智能安全风险分级体系，此设计有助于未来根据人工智能技术发

展和应用场景的多样性建立差异化、渐进式的个人信息安全治理机制，如对低风险应用鼓励创新，对高风险场景严格监管，从而为包容审慎和分类分级监管原则的落地施行提供了具体指引和可操作锚点。

从技术发展角度看，中国以DeepSeek为代表的新一代生成式人工智能通过开源生态、决策透明和灵活部署等创新显著提升了数据可追溯性、模型可解释性及生成内容质量，有助于从技术层面纾解个人信息安全治理方面困境。在此背景下，中国应融合创新和监管，积极探索与政策和技术进步相适应的平衡治理路径^[39]。具体而言，即构建以包容审慎为核心、风险分级为导向，覆盖数据采集、模型运行与内容生成的全阶段风险分级体系，并将生成式人工智能技术创新嵌入不同层级的风险治理场景之中（图1），实现“低风险领域施以包容、激励创新，高风险领域强化审慎、严守底线”，走出一条兼具治理效能与发展活力的中国式治理道路。




图1 生成式人工智能个人信息安全治理策略体系

Fig.1 Generative artificial intelligence personal information security governance strategy system

5.1 数据采集环节的风险分级与治理

高风险采集行为主要涉及敏感个人信息或已明确拒绝授权采集的个人信息。在基础大模型训练数据中，敏感个人信息所占比重极小，应秉持保护优先的原则，避免将其作为训练语料予以采集^[40]。可依托开源生态明确 robots 协议或开发统一监控工具，明确禁

止抓取数据范围并对违规采集予以实时检测。对金融、医疗等确有敏感个人信息采集必要的垂直细分领域，应按法律要求严格落实采集前的充分知情与单独同意，并通过开源社区建立协同审计机制，定期评估确保数据采集可信可控。

中风险采集主要涉及已公开的一般个人信息。在生成式人工智能通用化应用场景中，此类信息多用于

机器学习而非数据分析，对信息主体的影响相对较低^[41]。为平衡个人信息保护与技术创新发展，建议对《个人信息保护法》第27条作宽松解释，对采集已公开个人信息的行为遵循默认许可、例外禁止的合理使用模式：一是通过官网或开源社区公示信息来源，确立默示同意规则；二是将信息主体明确拒绝作为采集红线并建立动态授权机制，保障用户撤回同意的便利性；三是严格履行安全保护义务，尽可能消减采集行为给用户带来的风险。

低风险采集主要包括匿名化数据或其他公开数据。《个人信息保护法》第4条已将匿名化数据排除在个人信息保护范围外，但过度匿名化可能影响数据效用，且存在被重新识别的风险^[42]。应推动联邦学习与合成数据技术与DeepSeek开源生态深度融合，在开源框架下建立公共服务平台，协作优化数据合成算法，通过社区持续监测改进技术方案，实现风险管控与创新活力的有机统一。

5.2 模型运行环节的风险分级与治理

高风险运行涉及特定模型对敏感个人信息的深度处理。相较于基础大模型，医疗、金融、法律等存在敏感个人信息处理必要的细分领域在个人信息处理目的和范围方面通常更易于明确，如分析用户体检数据进行医疗诊断或汇总用户财务指标开展信用评估等。因此对于细分领域的高风险运行行为，应首先明确处理目的与范围，获取用户明确授权，并禁止超出授权的深度加工。其次，基于DeepSeek的可视化决策路径建立动态监控机制，便于用户和监管方实时追踪敏感信息处理轨迹。监管部门可要求平台完善决策记录保存制度，为事后审计提供依据。另外，应赋予用户更高层级的知情权与决定权，允许其根据决策重要性调整授权范围。

中风险运行包括基础模型对已公开个人信息的常规处理。在此层面，应以DeepSeek的可解释工具为支撑，构建用户参与的协同治理平台。一是平台须履行公开透明义务，提供用户易查询的数据处理报告和决策说明；二是建立基于“默认允许、例外禁止”的多层动态授权机制，允许用户灵活调整授权范围。如DeepSeek用户可通过打开或关闭“数据用于优化体

验”选择是否将输入数据用于模型优化^[43]；三是建立用户反馈渠道，确保模型出现偏见或错误能及时纠正并迭代改进。

低风险运行主要指对匿名化、合成或聚合数据的处理。尽管这些数据经过脱敏，仍存在被重新识别的风险。该场景下应构建低成本、高效率的安全方案，如自动标识敏感节点并建立风险预警机制。当当检测到数据关联可能引发重新识别风险时，系统应及时预警并调整处理策略。同时，基于决策透明技术开展持续监控，通过分析决策推理过程和历史风险优化运行策略，在控制合规成本的同时防范个人信息安全隐患。

5.3 内容生成环节的风险分级与治理

针对高风险内容生成，如医疗、金融等涉及敏感数据的垂直领域，技术层面可采用模型蒸馏、领域适应与本地化部署等，使模型在保持专业能力的同时实现私有环境的轻量化部署，确保敏感个人信息在本地环境中的存储安全与输出内容质量。政策层面应通过建立行业准入与专项评估机制确立强制性监管原则，并借鉴欧盟“监管沙盒”模式，在可控范围内测试社会影响，逐步完善监管规则。

中风险内容生成行为常见于商业咨询、教育辅助等一般个人信息输出场景。技术上应发挥DeepSeek的定制化能力，结合数据分析、人工审核与用户反馈，持续优化生成逻辑、识别并纠正生成内容中的错误或偏见。政策上可通过制定行业标准引导平台建立内容质量控制机制，并畅通用户反馈渠道，形成社会监督与专业监管的合力。

低风险内容生成主要涉及匿名化或个人特征较弱的处理场景。针对其中有可能产生的个人信息再识别和泄露，技术上可借助自动化筛查工具，以较低成本实现基本安全防护；政策上可通过负面清单明确禁止性内容，同时鼓励采用行业自律、标准引领等软性治理手段，在守住安全底线的同时为创新预留充分空间。

6 结 语

本研究从国内外生成式人工智能模型的技术演进

视角出发,系统对比不同模型差异,并深入剖析生成式人工智能在数据采集、模型训练与内容生成环节中对个人信息保护构成的风险和挑战。研究表明,相较于国外主流模型,中国自主创新的生成式人工智能 DeepSeek 具备开源可溯、决策透明与灵活部署等技术特性,为实施精细化、差异化的个人信息安全分级治理提供了重要的技术基础。随着生成式人工智能技术加速融入经济社会发展各领域,个人信息安全治理需从单一法律规制视角,转向技术特性与制度设计相融合的生态系统构建。未来研究可在当前框架基础上,进一步整合行业自律、社会协同与国际协作等多维度治理要素,并通过实证研究持续检验治理框架的适用性与有效性。通过持续完善适应技术动态发展、兼顾安全与创新的治理体系,不仅能为中国人工智能产业健康发展提供坚实保障,也能为全球人工智能治理贡献具有实践意义的中国方案。

参考文献:

- [1] 尹玉涵,李剑.生成式人工智能的个人信息保护问题及其规制[J].海南大学学报(人文社会科学版),2025,43(5):130-140.
Yin Yuhan, Li Jian. The problems of personal information protection in generative artificial intelligence and its regulations[J]. Journal of Hainan University (Humanities & Social Sciences), 2025, 43(5): 130-140.
- [2] Maura C. OpenAI is being sued for training ChatGPT with "stolen" personal data[EB/OL]. (2023-06-29)[2025-10-07]. <https://mashable.com/article/openai-chatgpt-class-action-lawsuit>.
- [3] 谷歌 Gemini 提示注入漏洞通过恶意邀请暴露私人日历数据[EB/OL]. (2026-01-20) [2026-01-25]. https://www.sohu.com/a/978184688_114765.
- [4] 腾讯网. DeepSeek-OCR 2 大模型开源,重塑文档 AI 的认知逻辑[EB/OL]. (2026-01-27) [2026-01-27]. <https://news.qq.com/rain/a/20260127A05UKG00>.
- [5] 朱荣荣.生成式人工智能对个人信息保护的挑战及应对[J].重庆大学学报(社会科学版),2025,31(4):222-235.
Zhu Rongrong. The challenge and response to personal information protection for generative artificial intelligence[J]. Journal of Chongqing University (Social Science Edition), 2025, 31(4): 222-235.
- [6] 黄镔.生成式 AI 对个人信息保护的挑战与风险规制[J].现代法学,2024,46(4):101-115.
Huang Pei. The challenge of generative artificial intelligence to personal information protection and its risk regulation[J]. Modern Law Science, 2024, 46(4): 101-115.
- [7] 叶雄彪.生成式人工智能背景下的个人信息保护:范式转换与规则完善[J].法学家,2025(4):61-73,192.
Ye Xiongbiao. Personal information protection in the context of generative artificial intelligence: Paradigm shift and rule improvement[J]. The Jurist, 2025(4): 61-73, 192.
- [8] 李川.生成式人工智能场域下个人信息规范保护的模与路径[J].江西社会科学,2024,44(8):68-80.
Li Chuan. Models and paths for the normative protection of personal information in the field of generative artificial intelligence[J]. Jiangxi Social Sciences, 2024, 44(8): 68-80.
- [9] 王松磊.迈向敏捷治理:人工智能时代的现实要求、推进动力与路径策略[J].河北大学学报(哲学社会科学版),2025,50(5):125-136.
Wang Songlei. Toward agile governance: Realistic requirements, driving forces, and pathway strategies in the age of artificial intelligence[J]. Journal of Hebei University (Philosophy and Social Science), 2025, 50(5): 125-136.
- [10] 莫旻丹,张焕培.从“赋权保护”到“信义保护”:生成式人工智能中个人信息保护的范式转型[J].征信,2024,42(12):21-29.
Mo Mindan, Zhang Huanpei. From empowerment protection to fiduciary protection: The paradigm shift in personal information protection within generative artificial intelligence[J]. Credit Reference, 2024, 42(12): 21-29.
- [11] 薛霏,王静静,叶鹰. DeepSeek 推动下生成式 AI 走势及其图书馆应用前景探析[J].图书馆杂志,2025,44(5):43-50.
Xue Fei, Wang Jingjing, Ye Ying. On the trends of GenAI driven by DeepSeek with application prospects in libraries[J]. Library Journal, 2025, 44(5): 43-50.
- [12] 吴若航,蒯意宏.“图书馆+DeepSeek”的应用路径研究[J].图书与情报,2025(2):67-77.
Wu Ruohang, Mao Yihong. Research on the application pathway of "Library+DeepSeek"[J]. Library & Information, 2025(2): 67-77.
- [13] 徐翼.生成式人工智能中个人数据安全治理的中国模式——以 DeepSeek 为例[J].重庆社会科学,2025(5):61-74.
Xu Yi. A Chinese model of personal data security governance in generative AI: Take DeepSeek as an example[J]. Chongqing Social Sciences, 2025(5): 61-74.
- [14] 邓建鹏,赵治松. DeepSeek 的破局与变局:论生成式人工智能的监管方向[J].新疆师范大学学报(哲学社会科学版),2025,46(4):99-108.
Deng Jianpeng, Zhao Zhisong. The breakthrough and transformation of DeepSeek: The new rules for AIGC regulation[J]. Journal of Xinjiang Normal University (Edition of Philosophy and Social Sciences), 2025, 46(4): 99-108.
- [15] 魏钰明,贾开,曾润喜,等. DeepSeek 突破效应下的人工智能创新发展与治理变革[J].电子政务,2025(3):2-39.
Wei Yuming, Jia Kai, Zeng Runxi, et al. Innovative development and governance reform of artificial intelligence under the breakthrough effect of DeepSeek[J]. E-Government, 2025(3): 2-39.
- [16] Neha F, Bhati D. A survey of DeepSeek models[EB/OL]. (2025-02-07) [2025-10-09]. <https://www.techrxiv.org/users/876974/articles/1265081>.
- [17] 百度智能云.深度解析: DeepSeek 与 ChatGPT 的成本对比与价值评估[EB/OL]. (2025-09-12) [2026-01-24]. <https://cloud.baidu.com/article/3560927>.
- [18] 张慧敏. DeepSeek-R1 是怎样炼成的?[J].深圳大学学报(理工版),2025,42(2):226-232.
Zhang Huimin. How DeepSeek-R1 was created? [J]. Journal of Shenzhen University (Science & Engineering), 2025, 42(2): 226-232.
- [19] 郭亚军,徐苑茜,梁艳丽,等.从 ChatGPT 到 DeepSeek:生成式人工智能迭代对图书馆的影响[J].图书馆论坛,2025,45(7):140-149.
Guo Yajun, Xu Yuanqian, Liang Yanli, et al. From ChatGPT to DeepSeek: The impact of generative artificial intelligence iterations on libraries[J]. Library Tribune, 2025, 45(7): 140-149.
- [20] Proser Z. Breaking the AI mold: China's DeepSeek-R1 pushes local and open AI forward[EB/OL]. (2025-01-23) [2025-10-09]. <https://workos.com/blog/deepseek-r1-pushes-local-and-open-ai-forward>.
- [21] 程啸.论我国个人信息保护法中的个人信息处理规则[J].清华法学,2021,15(3):55-73.
Cheng Xiao. On the rules for handling personal information in China's personal information protection law[J]. Tsinghua University Law Journal, 2021, 15(3): 55-73.
- [22] 钟晓东.风险与控制:论生成式人工智能应用的个人信息保护[J].政法论坛,2023(4):59-68.
Tou Xiaodong. Risk and control: On the protection of personal information in generative artificial intelligence applications[J]. Journal of Political Science and Law, 2023(4): 59-68.

- [23] 杨清望, 唐乾. 生成式人工智能与个人信息保护法律规范的冲突及其协调[J]. 河南社会科学, 2024, 32(12): 81-93.
Yang Qingwang, Tang Qian. The conflict and governance of generative artificial intelligence and personal information protection laws[J]. Henan Social Sciences, 2024, 32(12): 81-93.
- [24] 欧阳爱辉, 马雨珊. 图书馆应用生成式人工智能数据风险法律治理[J]. 图书馆工作与研究, 2025(1): 35-40.
Ouyang Aihui, Ma Yushan. Legal governance of data risks of generative artificial intelligence in library applications[J]. Library Work and Study, 2025(1): 35-40.
- [25] 喻钊. 生成式人工智能应用下读者个人信息协同保护研究[J]. 图书馆工作与研究, 2024(12): 36-43.
Yu Zhao. Research on synergistic protection of Readers' Personal information in the application of generative artificial intelligence[J]. Library Work and Study, 2024(12): 36-43.
- [26] 张素华, 李凯. 生成式人工智能虚假信息风险与治理研究[J]. 学术探索, 2024(7): 129-140.
Zhang Suhua, Li Kai. Research on risk and governance of the disinformation by generative artificial intelligence[J]. Academic Exploration, 2024(7): 129-140.
- [27] 刘佳. 基于生成式人工智能的智能图书馆服务创新与风险规避[J]. 农业图书情报学报, 2024, 36(7): 63-75.
Liu Jia. Innovation and risk avoidance of smart library services based on generative artificial intelligence[J]. Journal of Library and Information Science in Agriculture, 2024, 36(7): 63-75.
- [28] March 20 ChatGPT outage: Here's what happened[EB/OL]. (2023-03-24) [2025-10-09]. <https://openai.com/index/march-20-chatgpt-outage/>.
- [29] 网络安全技术 生成式人工智能服务安全基本要求[EB/OL]. (2025-04-25)[2025-10-18]. <https://www.tc260.org.cn/upload/2025-06-30/1751257342816036759.pdf>.
- [30] Data provenance initiative[EB/OL]. (2025-02-11) [2025-10-18]. <https://www.dataprovenance.org/about>.
- [31] DeepSeek 不止于效率：迈向可解释的 AI[EB/OL]. (2025-02-11) [2025-10-18]. https://www.thepaper.cn/newsDetail_forward_30121855.
- [32] 陈禹衡. 生成式人工智能中个人信息保护的全流程合规体系构建[J]. 华东政法大学学报, 2024, 27(2): 37-51.
Chen Yuheng. Construction of a whole-process compliance system for personal information protection in generative artificial intelligence[J]. ECUPL Journal, 2024, 27(2): 37-51.
- [33] 阿里云. DeepSeek 模型解释与可视化[EB/OL]. (2025-02-11) [2025-10-10]. <https://developer.aliyun.com/article/1653885>.
- [34] 百度开发者中心. DeepSeek 本地部署与知识库搭建实战指南[EB/OL]. (2025-03-11) [2025-09-11]. <https://developer.baidu.com/article/detail.html?id=3426121>.
- [35] DeepSeek 走进银行[EB/OL]. (2025-03-11) [2025-10-11]. <https://finance.sina.com.cn/jjxw/2025-02-04/doc-ineiwx5906975.shtml>.
- [36] 多家医院完成 DeepSeek 本地化部署, 数据安全与患者隐私保护至关重要[EB/OL]. (2025-02-15) [2025-10-18]. <https://news.qq.com/rain/a/20250215A04WXZ00>.
- [37] 生成式人工智能服务管理暂行办法[EB/OL]. (2023-07-13) [2025-11-07]. https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm.
- [38] 《人工智能安全治理框架》2.0 版发布[EB/OL]. (2025-09-15) [2025-11-10]. https://www.cac.gov.cn/2025-09/15/c_1759653448369123.htm.
- [39] 张涛, 吕莺慧. 欧美生成式人工智能治理实践对中国的启示研究[J]. 农业图书情报学报, 2025, 37(4): 12-23.
Zhang Tao, Lyu Qianhui. Generative AI governance practices in Europe and the United States and the enlightenment for China[J]. Journal of Library and Information Science in Agriculture, 2025, 37(4): 12-23.
- [40] 张新宝. 生成式人工智能训练语料的个人信息保护研究[J]. 中国法学, 2024(6): 86-107.
Zhang Xinbao. Research on personal information protection of generative AI training language material[J]. China Legal Science, 2024(6): 86-107.
- [41] 胡宏涛. 论生成式人工智能服务提供者的个人信息合理使用[J]. 江苏社会科学, 2024(2): 185-192.
Hu Hongtao. On the rational use of personal information of generative artificial intelligence service providers[J]. Jiangsu Social Sciences, 2024(2): 185-192.
- [42] 玛丽亚木·艾斯凯尔. 合成数据：生成式人工智能数据训练中隐私保护和数据利用并行的新路径[J]. 图书馆建设, 2025(4): 111-119, 134.
Maliyamu A. Synthetic data: A new path of parallel implementation for privacy protection and data utilization in GAI data training[J]. Library Development, 2025(4): 111-119, 134.
- [43] DeepSeek 隐私政策[EB/OL]. (2025-05-29) [2025-11-10]. <https://cdn.deepseek.com/policies/zh-CN/deepseek-privacy-policy.html>.

Governance of Personal Information Security in the Iteration of Generative AI: From the Perspective of the Technological Evolution of Large Models

AN Lin

(Shaanxi Library, Xi'an 710061)

Abstract: [Purpose/Significance] The rapid advancement of generative artificial intelligence (AI) is driving societal digital transformation, yet it simultaneously poses unprecedented systemic risks to personal information security due to the large-scale, automated, and complex nature of its data processing. Previous research has lacked exploration of governance pathways that consider endogenous technological evolution and specific model iterations. This paper takes the technological evolution of mainstream, large-scale generative AI models, both domestically and internationally as a starting point, and systematically reveals the impact of

generative AI on personal information protection principles across the stages of data collection, model operation, and content generation. The focus is on analyzing how technological innovations in China's DeepSeek, including open-source traceability, decision transparency, and flexible deployment, lay the groundwork for risk-graded governance. This study not only broadens the theoretical perspective on AI governance and promotes the formation of a "technology-institution" collaborative governance paradigm, but also offers innovative and actionable insights for building an agile and effective personal information protection system in China amidst the rapid adoption of generative AI. [Method/Process] This study employs a comparative analysis and inductive research approach. First, it systematically compares the core technological differences among mainstream generative AI models, both domestic and international, across three dimensions: model ecosystem, model capabilities, and deployment methods. Through this comparison, it analyzes the challenges generative AI poses to personal information protection at various stages, including data collection, model operation, and content generation. Second, the study systematically examines the differentiated impacts brought about by DeepSeek's technological iterations on personal information security governance. Building on this foundation, the research proposes a comprehensive governance strategy centered on the principles of inclusiveness and prudence, guided by risk grading, and covering all operational stages of generative AI. This strategy emphasizes the critical role of DeepSeek's technical characteristics in supporting the implementation of this framework. [Results/Conclusions] The research indicates that constructing a risk-graded governance system based on the sensitivity of personal information is an effective approach to balancing security and innovation in generative AI. This system emphasizes distinguishing between sensitive and general information during data collection, achieving traceability and purpose control during model operation, and implementing differentiated security safeguards during content generation. With its technical advantages, including open-source traceability, decision transparency, and flexible deployment, DeepSeek provides technical validation and practical possibilities for graded governance. This facilitates the protection of sensitive personal information in high-risk scenarios while simultaneously fostering technological iteration and application innovation in medium- to low-risk contexts. Future research should further incorporate multi-dimensional governance elements such as industry self-regulation, social coordination, and international collaboration. Empirical analysis should also be conducted to test the applicability and effectiveness of the governance framework, thereby gradually developing a well-rounded personal information security governance scheme that adapts to the dynamic evolution of technology.

Keywords: generative artificial intelligence; personal information security; DeepSeek; risk classification